

# Previsão de Séries Temporais na Presença de Mudança de Conceito

Gustavo H. Ferreira de Miranda Oliveira  
gustavo.oliveira@penedo.ufal.br



Centro de Informática – UFPE  
27/10/2022



## Tópicos

1. Séries Temporais e Fluxos de Dados.
2. O que é Mudança de Conceito?
3. Mudança de Conceito em Classificação.
4. Mudança de Conceito em Séries Temporais.
5. Detecção de Pontos de Mudança em Séries Temporais
6. Previsão de Séries Temporais com Mudança de Conceito



## Tópicos

---


1. Séries Temporais e Fluxos de Dados.
2. O que é Mudança de Conceito?
3. Mudança de Conceito em Classificação.
4. Mudança de Conceito em Séries Temporais.
5. Detecção de Pontos de Mudança em Séries Temporais
6. Previsão de Séries Temporais com Mudança de Conceito



## Séries Temporais

Uma **série temporal** é uma coleção de **observações medidas sequencialmente ao longo do tempo**:

- Casos confirmados de COVID
- Mortes por COVID
- Movimento do preço de ações;
- Taxas de câmbio;
- Temperaturas de uma cidade;
- Entre outros.




**Fonte:** Dados OMS Brasil 2022



## Previsão de Séries Temporais

- A maioria das abordagens de séries temporais **modelam** os dados **de forma estática**.
  - Processam a série temporal de modo *off-line*.
  - Processamento dos dados históricos em várias etapas.
- No entanto, **na maioria das aplicações** de séries temporais do mundo real, os dados chegam sequencialmente em um **fluxo de dados**.
  - Os dados podem fluir em alta velocidade e evoluir ao longo do tempo.




Representação da chegada de novos dados em séries do mundo real. **Fonte:** Yahoo Finanças.



## Séries Temporais e Fluxos de Dados

- **Fluxos de Dados** (em inglês Data Streams) são caracterizados por **uma grande quantidade de instâncias** que chegam rapidamente e necessitam de uma **resposta em tempo real**. (Dongre et al, 2014).
- Com o crescimento das tecnologias da internet a quantidade de dados tornou-se **cada vez maior**. (Diztiler et al, 2015).





## Desafios dos Fluxos de Dados

- **Exemplos de aplicações:**
  - Análise de mercado;
  - Filtragem de informações;
  - Controle de processos industriais; e etc. (Minku et al, 2012)
- Fluxos de Dados **representam novos desafios** para o campo de **aprendizagem de máquina** e mineração de dados, já que os métodos tradicionais foram projetados para conjuntos de dados estáticos. (Krawczyk et al, 2017)
- Um desses desafios é a **mudança de conceito** (em inglês Concept Drift). (Krawczyk et al, 2017)



## Tópicos

---

1. Séries Temporais e Fluxos de Dados.
2. O que é Mudança de Conceito?
3. Mudança de Conceito em Classificação.
4. Mudança de Conceito em Séries Temporais.
5. Detecção de Pontos de Mudança em Séries Temporais
6. Previsão de Séries Temporais com Mudança de Conceito





## O que é mudança de conceito?

- Um **exemplo típico** de uma mudança de conceito real é uma **mudança nos interesses do usuário** ao seguir um fluxo de notícias on-line. (Gama et al, 2014).
- Mudança de conceito é inerente aos fluxos de dados e **consiste em uma mudança na relação entre os dados de entrada e a variável alvo ao longo do tempo**. (Cavalcante et al, 2015).





## Mudança de conceito

### Modelo de aprendizagem de máquina:

- Conjunto de entradas:  $X$
- Conjunto de alvos:  $y$
- Treinamento:  $F: X \rightarrow y$

### Processo Gerador dos Dados:

- Cada observação  $(x, y)$  vem de um fluxo dados gerado por uma distribuição de probabilidade  $P(X, y)$ .
- Distribuição de probabilidade conjunta é  $P(X, y) = P(y|X) P(X)$ .
- $P(y|X)$  é a função que relaciona o conjunto de entradas  $X$  com o conjunto de saídas  $y$ .
- $P(X)$  é a distribuição dos componentes de entrada  $X$ .

### Mudança de conceito:

- $P(y|X)$ : Mudanças reais
- $P(X)$ : Mudanças virtuais.



## Tópicos

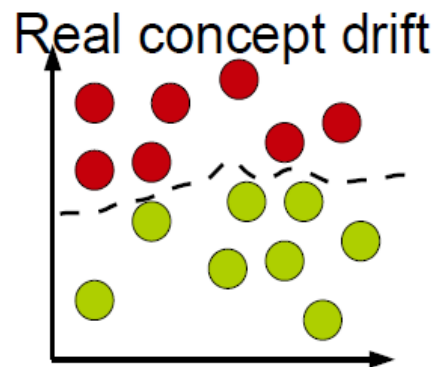

---

1. Séries Temporais e Fluxos de Dados.
2. O que é Mudança de Conceito?
- 3. Mudança de Conceito em Classificação.**
4. Mudança de Conceito em Séries Temporais.
5. Detecção de Pontos de Mudança em Séries Temporais
6. Previsão de Séries Temporais com Mudança de Conceito



## Mudança de Conceito em Classificação

- A evolução dos dados **impõe um grande desafio** aos algoritmos tradicionais de aprendizagem por lotes, já que o modelo aprendido a partir dos dados **pode tornar-se obsoleto** (Cavalcante et al, 2015).
- **Aprender a evoluir** a transmissão de dados tornou-se um **tema de pesquisa "quente"** na última década e muitos algoritmos de aprendizagem adaptativos foram desenvolvidos. (Zliobaite et al, 2012).





## Tópicos


---

1. Séries Temporais e Fluxos de Dados.
2. O que é Mudança de Conceito?
3. Mudança de Conceito em Classificação.
4. **Mudança de Conceito em Séries Temporais.**
5. Detecção de Pontos de Mudança em Séries Temporais
6. Previsão de Séries Temporais com Mudança de Conceito



## Mudança de Conceito em Séries Temporais

- O processo de **geração dos dados** pode **mudar ao longo do tempo** (Cavalcante et al, 2015);
- **Observações históricas não são úteis** para definir comportamentos futuros (Oliveira et al, 2017).
  - Prejudicam fortemente as previsões.





## Tópicos


---

1. Séries Temporais e Fluxos de Dados.
2. O que é Mudança de Conceito?
3. Mudança de Conceito em Classificação.
4. Mudança de Conceito em Séries Temporais.
- 5. Detecção de Pontos de Mudança em Séries Temporais**
6. Previsão de Séries Temporais com Mudança de Conceito



## Detecção de Pontos de Mudanças em Séries Temporais

- São métodos que têm como objetivo principal a **detecção de pontos de mudança**, que são **instantes de tempo** quando ocorreram **mudanças de conceito**. (Cavalcante et al, 2016).
- A detecção de pontos de mudança é **útil na modelagem e previsão de séries temporais** e também em outras áreas de aplicação como **finanças, biometria e robótica**. (Adams et al, 2007).
- Essas abordagens são baseadas em uma **análise estatística retrospectiva** dos dados da série temporal ou dos resíduos para identificação de pontos de mudança. (Cavalcante et al, 2016).








## Detecção de Pontos de Mudanças em Séries Temporais

- Outra questão desses métodos é que eles são projetados para **funcionar apenas com mudanças de conceito abruptas**. A detecção é feita **após receber várias amostras do fluxo de dados**. (Cavalcante et al, 2016).




Fonte: (Adam, 2007).



## Detecção de Pontos de Mudanças em Séries Temporais

- **124:** Condenação dos assessores do ex-presidente Nixon, G. Gordon Liddy e James W. McCord, Jr. Em 30 de Janeiro de 1973.
- **307:** Inicio do embargo OPEC contra os Estados Unidos em 19 de outubro de 1973.
- **510:** A renúncia do ex-presidente Nixon em 9 de agosto de 1974.



Dow Jones – Jan de 1973 à Jun de 1975.



## Tópicos

---

1. Séries Temporais e Fluxos de Dados.
2. O que é Mudança de Conceito?
3. Mudança de Conceito em Classificação.
4. Mudança de Conceito em Séries Temporais.
5. Detecção de Pontos de Mudança em Séries Temporais
6. Previsão de Séries Temporais com Mudança de Conceito



## Área de Pesquisa em Evidência

- Apenas **algumas pesquisas** investigaram o problema de mudança de conceito em séries temporais e como lidar com isso para **manter o modelo aprendido atualizado** e capaz de fazer previsões precisas. (Cavalcante et al, 2016).
- Apesar de que **previsão de séries temporais não é uma nova área de pesquisa**, vários **desafios permanecem em aberto na literatura**, como por exemplo o **estudo de mudança de conceito**. (Cavalcante et al, 2016)





## Dissertações de Mestrado

1. OLIVEIRA, Gustavo Henrique Ferreira de Miranda et al. **Previsão de Séries Temporais na Presença de Mudança de Conceito: uma Abordagem baseada em PSO.** 2018. Dissertação de Mestrado. Universidade Federal de Pernambuco.
2. SCHETTINI, Gabriela Mota de Lacerda Padilha et al. **Um Método Baseado em Correção de Erros Para Previsão de Séries Temporais em Ambiente Online e Na Presença De Concept Drift.** 2020. Dissertação de Mestrado. Universidade Federal de Pernambuco.
3. LEAL, Denisson Augusto Bastos et al. **Ensembles Dinâmicos para Detecção de Concept Drift em Séries Temporais.** 2022. Dissertação de Mestrado. Universidade Federal de Pernambuco.



## Trabalhos Publicados

1. Cavalcante, Rodolfo C., and Adriano LI Oliveira. "**An approach to handle concept drift in financial time series based on Extreme Learning Machines and explicit Drift Detection.**" *2015 international joint conference on neural networks (IJCNN)*. IEEE, 2015.
2. Cavalcante, Rodolfo C., Leandro L. Minku, and Adriano LI Oliveira. "**FEDD: Feature Extraction for Explicit Concept Drift Detection in time series.**" *Neural Networks (IJCNN), 2016 International Joint Conference on*. IEEE, 2016.
3. Oliveira, Gustavo H. F de M., Cavalcante, Rodolfo C., Cabral, George G., Leandro L. Minku, and Adriano LI Oliveira. "**Time Series Forecasting in the Presence of Concept Drift: A PSO-based Approach.**" *Tools with Artificial Intelligence (ICTAI), 2017 IEE 29th International Conference on*. IEE, 2017.



## Trabalhos Publicados

1. Cavalcante, Rodolfo C., and Adriano LI Oliveira. **"An approach to handle concept drift in financial time series based on Extreme Learning Machines and Explicit Drift Detection."** *2015 international joint conference on neural networks (IJCNN)*. IEEE, 2015.
2. Cavalcante, Rodolfo C., Leandro L. Minku, and Adriano LI Oliveira. **"FEDD: Feature Extraction for Explicit Concept Drift Detection in Time Series."** *Neural Networks (IJCNN), 2016 International Joint Conference on*. IEEE, 2016.
3. Oliveira, Gustavo H. F de M., Cavalcante, Rodolfo C., Cabral, George G., Leandro L. Minku, and Adriano LI Oliveira. **"Time Series Forecasting in the Presence of Concept Drift: A PSO-based Approach."** *Tools with Artificial Intelligence (ICTAI), 2017 IEE 29th International Conference on*. IEE, 2017.



## 1- Cavalcante et al (2015) - IJCNN

- **Objetivo:** Propõem uso de **mecanismos explícitos de detecção** de mudança de conceito a fim de **melhorar a previsão de séries temporais financeiras**.
- **Métodos Cegos ou Passivos:** OS-ELM.
- **Métodos Ativos:** DDM e ECDD.
- **Hipóteses de pesquisa:**
  - Se usar **ELM em combinação com um mecanismo de detecção** de mudança para atualizar o modelo aprendido quando a mudança ocorrer, **ele pode obter precisão similar ao OS-ELM**, mas **com maior eficiência**.
  - Semelhante a primeira pergunta, **se atualizar OS-ELM apenas quando a mudança ocorrer**, apresentaria **melhor eficiência** enquanto mantém uma **boa precisão**.
- **Contribuições:** Uma abordagem que combina **OS-ELM com detecção de mudança de conceito**. O modelo **atualiza apenas na presença de mudança** de conceito. A abordagem proposta apresenta o **mesmo desempenho de um OS-ELM convencional** porém com **menos esforço** computacional.






# 1- Cavalcante et al (2015) - IJCNN



Séries artificiais:






# 1- Cavalcante et al (2015) - IJCNN



Séries financeiras:

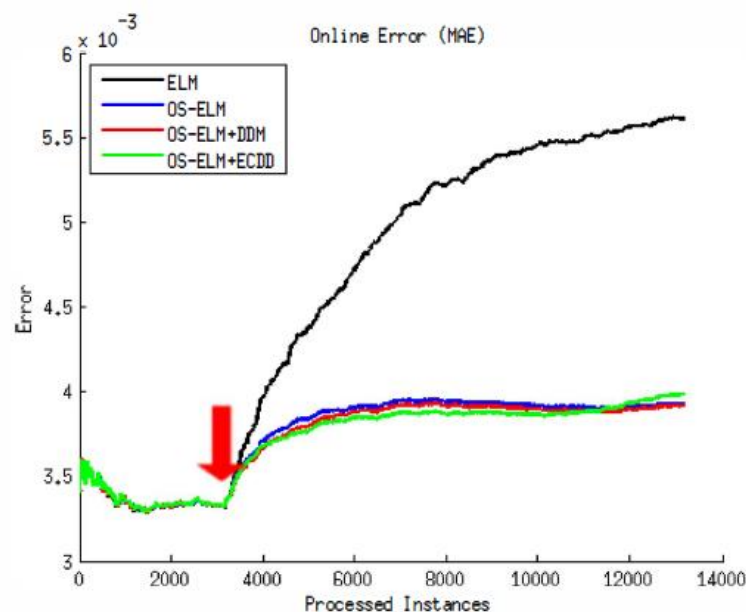





# 1- Cavalcante et al (2015) - IJCNN



## Principais Resultados:





## Trabalhos Relacionados

1. Cavalcante, Rodolfo C., and Adriano LI Oliveira. "An approach to handle concept drift in financial time series based on Extreme Learning Machines and explicit Drift Detection." *2015 international joint conference on neural networks (IJCNN)*. IEEE, 2015.
2. Cavalcante, Rodolfo C., Leandro L. Minku, and Adriano LI Oliveira. "**FEDD: Feature Extraction for Explicit Concept Drift Detection in time series.**" *Neural Networks (IJCNN), 2016 International Joint Conference on*. IEEE, 2016.
3. Oliveira, Gustavo H. F de M., Cavalcante, Rodolfo C., Cabral, George G., Leandro L. Minku, and Adriano LI Oliveira. "Time Series Forecasting in the Presence of Concept Drift: A PSO-based Approach." *Tools with Artificial Intelligence (ICTAI), 2017 IEE 29th International Conference on*. IEE, 2017.



## 2- Cavalcante et al (2016) - IJCNN


- **Objetivo:** Propõem um **método explícito de detecção** de mudança de conceito que identifica mudanças **monitorando características da própria série temporal**.
- Métodos de detecção **baseados no erro do modelo**: DDM, ECDD e PHt.
- Métodos de detecção **baseados nas características da série**: FEDD.
- **Hipóteses de pesquisa:**
  - Ao **monitorar características da série temporal** é possível construir um **método explícito de detecção** capaz de detectar mudanças de forma efetiva, **minimizando o atraso na detecção, alarmes falsos e taxas de detecção** em relação a **métodos baseados no erro** do modelo.
- **Contribuições:** A contribuição original deste trabalho é o **FEDD** (Feature Extraction for Explicit Concept Drift Detection), **um método de detecção explícito baseado em características de séries temporais**.




## 2- Cavalcante et al (2016) - IJCNN




Séries Artificiais:




Linear Time Series1




Linear Time Series2




Linear Time Series3



Nonlinear Time Series1



Nonlinear Time Series2



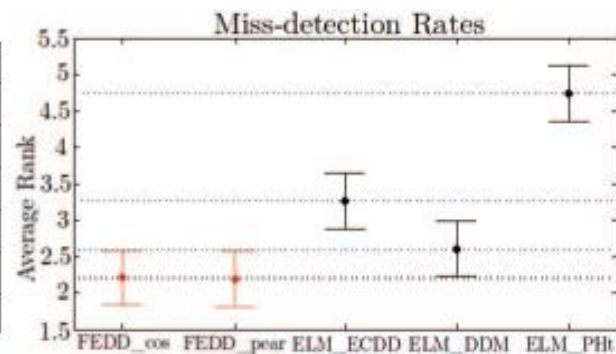
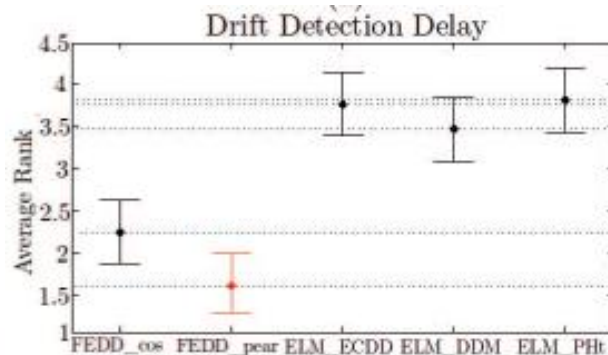
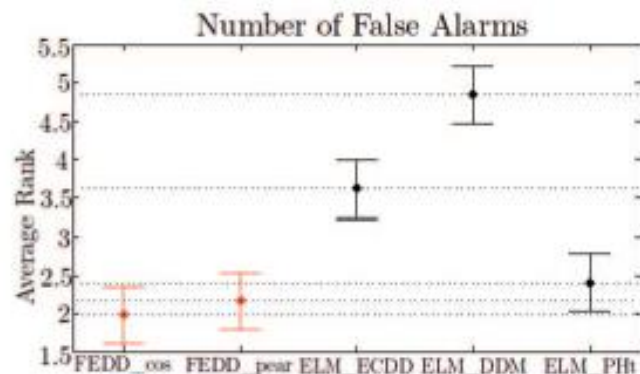
Nonlinear Time Series3



## 2- Cavalcante et al (2016) - IJCNN



### Principais Resultados:





## Trabalhos Relacionados

1. Cavalcante, Rodolfo C., and Adriano LI Oliveira. "**An approach to handle concept drift in financial time series based on Extreme Learning Machines and explicit Drift Detection.**" *2015 international joint conference on neural networks (IJCNN)*. IEEE, 2015.
2. Cavalcante, Rodolfo C., Leandro L. Minku, and Adriano LI Oliveira. "**FEDD: Feature Extraction for Explicit Concept Drift Detection in time series.**" *Neural Networks (IJCNN), 2016 International Joint Conference on*. IEEE, 2016.
3. Oliveira, Gustavo H. F de M., Cavalcante, Rodolfo C., Cabral, George G., Leandro L. Minku, and Adriano LI Oliveira. "**Time Series Forecasting in the Presence of Concept Drift: A PSO-based Approach.**" *Tools with Artificial Intelligence (ICTAI), 2017 IEE 29th International Conference on*. IEE, 2017.





### 3- Oliveira et al (2017) - ICTAI

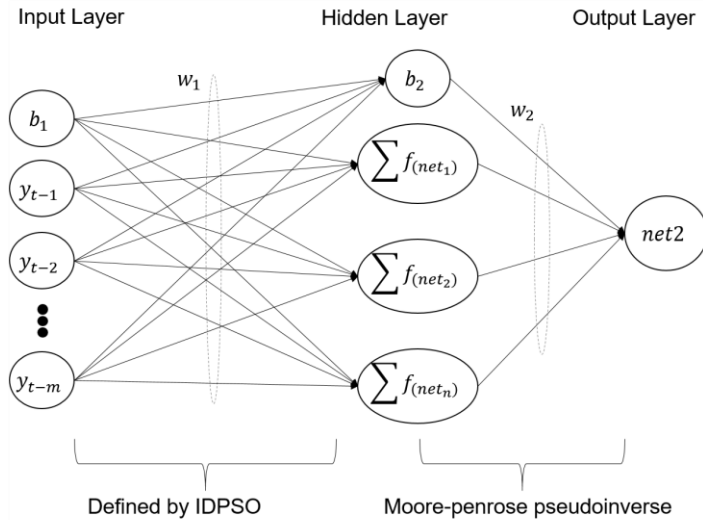
- **Objetivo:** Propõem um **sistema de aprendizagem adaptativo ativo** para previsão de séries temporais, com base no **monitoramento do erro de vários modelos de previsão** gerados por **inteligência de enxames**.
- Métodos de detecção **baseados em um modelo:** DDM, ECDD.
- Métodos de detecção **baseados em muitos modelos:** IDPSO-ELM-S, IDPSO-ELM-B.
- **Hipoteses de pesquisa:**
  - Quando ocorre uma **mudança no processo da geração de séries** temporais o **espaço de busca** enfrentado pelo PSO **reflete a mudança**. Assim, **em vez de monitorar o erro de um único método** de previsão, podemos **identificar a mudança** de conceito **ao monitorar uma área maior do espaço de busca** de otimização **através de vários modelos de previsão** gerados pelo PSO.
- **Contribuições:** Um **sistema** de aprendizagem **adaptativo** ativo que **monitora o erro de vários modelos** de previsão **baseado em inteligência de enxames**. O sistema proposto **atualiza o modelo preditivo** com inteligência de enxames **na presença de mudança de conceito**.



### 3- Oliveira et al (2017) - ICTAI



#### Método:







$w_{11}$	...	$w_{1n}$	$w_{2n}$	$w_{3n}$	...	$w_{mn}$	$b_{11}$	...	$b_{1n}$
----------	-----	----------	----------	----------	-----	----------	----------	-----	----------



## 3- Oliveira et al (2017) - ICTAI



### Séries artificiais:

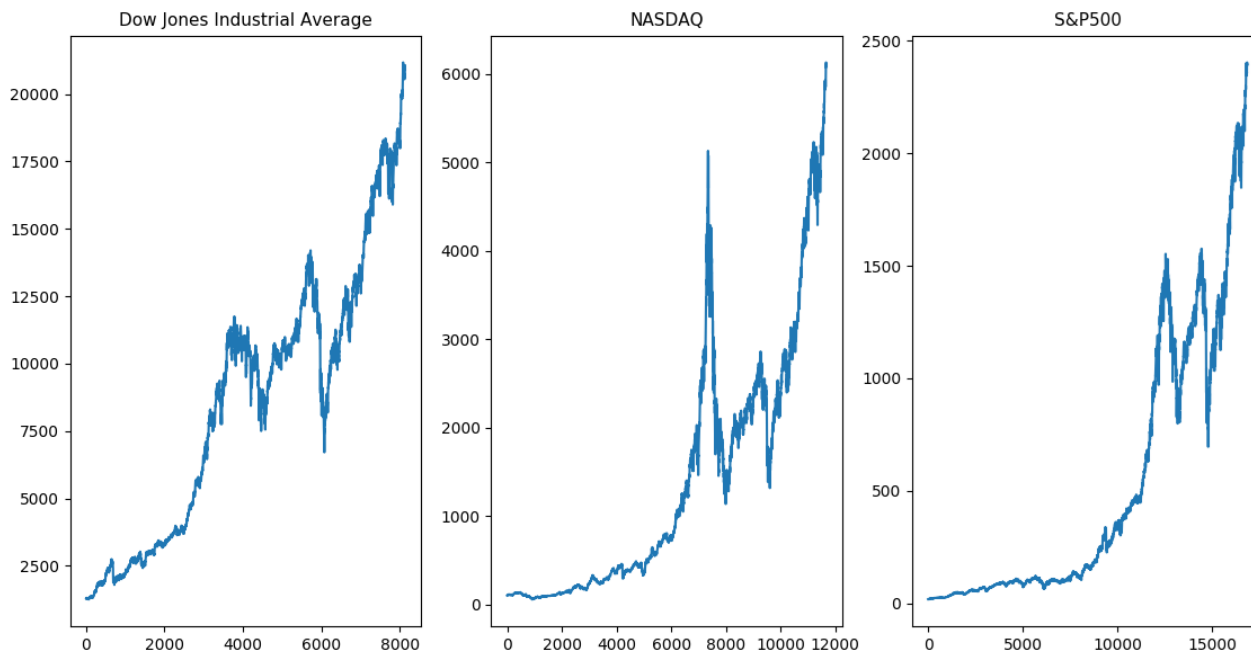




## 3- Oliveira et al (2017) - ICTAI



### Séries financeiras reais:






### 3- Oliveira et al (2017) - ICTAI



Avaliação sobre detecção de mudança de conceito.

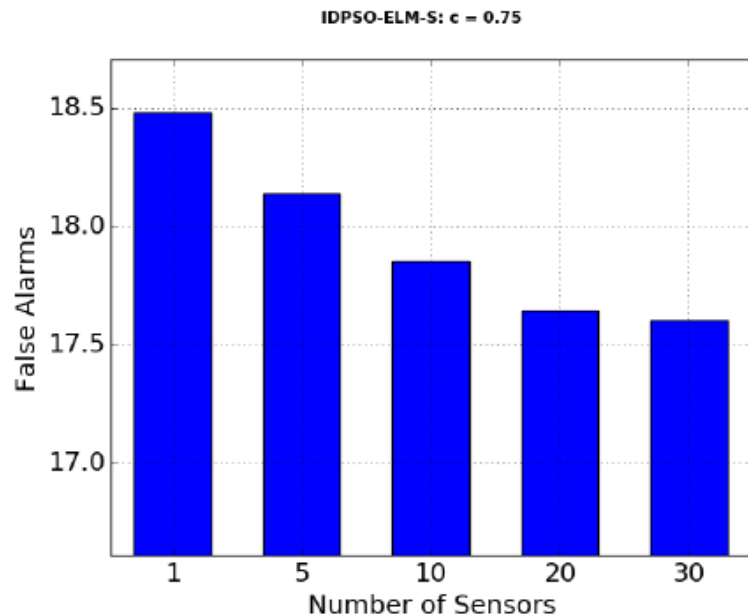




### 3- Oliveira et al (2017) - ICTAI



Influência dos **falsos alarmes** ao **variar a quantidade de sensores**.





### 3- Oliveira et al (2017) - ICTAI

● Avaliação sobre a previsão de séries temporais artificiais com mudança de conceito.


TABLE II  
MEAN ABSOLUTE ERROR FOR THE ARTIFICIAL DATASETS

Parameter - best MAE						
Dataset	ELM-FEDD	ELM-DDM	ELM-ECDD	IDPSO-ELM-B	IDPSO-ELM-S (1)	IDPSO-ELM-S (30)
Linear	0.02 (0.006)	0.02 (0.006)	0.024 (0.01)	<b>0.018 (0.003)</b>	0.019 (0.003)	0.02 (0.004)
Non Linear	0.045 (0.007)	0.045 (0.002)	0.045 (0.002)	0.044 (0.002)	0.044 (0.002)	<b>0.043 (0.002)</b>
Seasonal	0.066 (0.008)	0.066 (0.002)	0.067 (0.002)	0.064 (0.002)	0.064 (0.002)	<b>0.064 (0.001)</b>
Hybrid	0.066 (0.009)	0.056 (0.034)	0.07 (0.052)	<b>0.034 (0.008)</b>	0.04 (0.015)	0.04 (0.014)



### 3- Oliveira et al (2017) - ICTAI

○ Avaliação sobre a previsão de séries temporais artificiais com mudança de conceito.







### 3- Oliveira et al (2017) - ICTAI



Avaliação sobre a previsão de séries temporais financeiras.

TABLE III  
MEAN ABSOLUTE ERROR FOR THE REAL DATASETS

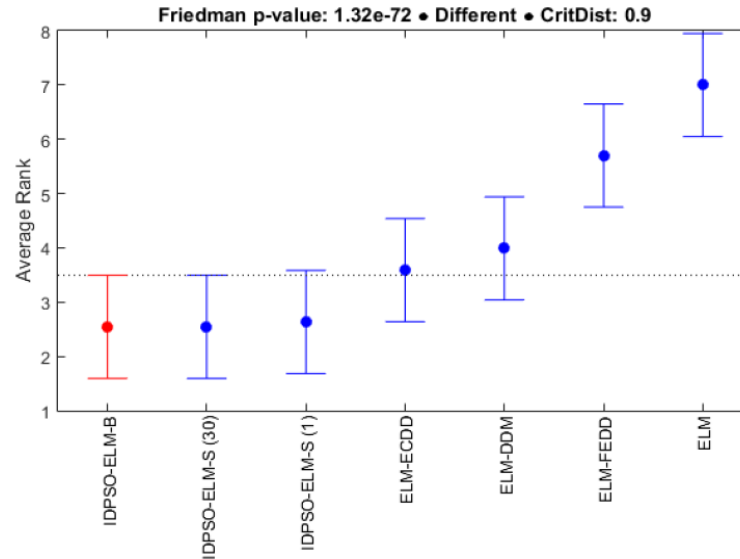
Dataset	ELM	ELM-FEDD	ELM-DDM	ELM-ECDD	IDPSO-ELM-B	IDPSO-ELM-S (1)	IDPSO-ELM-S (30)
Dow Jones	2.5206 (2.3946)	0.0495 (0.0214)	0.0112 (0.003)	0.0119 (0.003)	<b>0.0098 (0.0029)</b>	0.0102 (0.0024)	0.0104 (0.0024)
NASDAQ	4.374 (3.2291)	1.1112 (1.082)	0.0082 (0.0022)	0.0076 (0.0013)	0.0071 (0.0028)	0.0064 (0.0015)	<b>0.006 (0.002)</b>
S&P 500	16.2136 (12.0193)	0.5796 (0.5999)	0.0051 (0.0013)	0.0055 (0.0011)	0.0053 (0.0014)	0.0064 (0.002)	<b>0.0051 (0.001)</b>



### 3- Oliveira et al (2017) - ICTAI



Avaliação sobre a previsão de séries temporais financeiras.

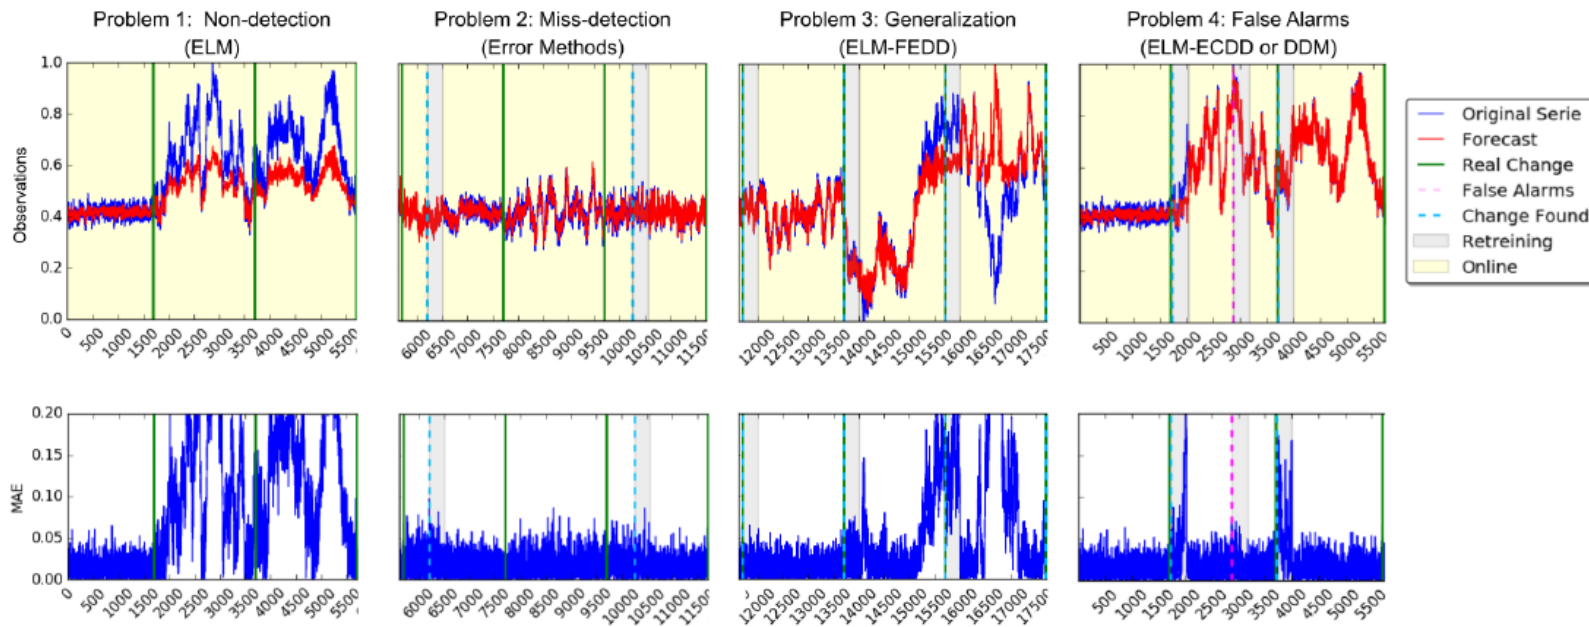




### 3- Oliveira et al (2017) - ICTAI



Avaliação sobre a previsão de séries temporais financeiras.





# Obrigado!



**Gustavo Henrique Ferreira  
de Miranda Oliveira**

GustavoHFMO

Overview

Repositories 9

Projects

Códigos dos artigos apresentados

Pinned

Order updated.

🖨 IDPSO-ELM-S

Public

⋮

Algorithms proposed in the following paper: OLIVEIRA, Gustavo HFMO et al. Time series forecasting in the presence of concept drift: A pso-based approach. In: 2017 IEEE 29th International Conference...

Python

☆ 7

🖨 TimeSeriesCln

Public

⋮

Repositório com os códigos para a monitoria da disciplina de séries temporais da pós-graduação em inteligência computacional do centro de informática (Cln) - UFPE.

Python

☆ 5

🔗 1

**Apresentação**

<https://github.com/GustavoHFMO>



## Referências

1. Adams, Ryan Prescott, and David JC MacKay. "Bayesian online changepoint detection." *arXiv preprint arXiv:0710.3742* (2007).
2. Cavalcante, Rodolfo C., and Adriano LI Oliveira. "An approach to handle concept drift in financial time series based on Extreme Learning Machines and explicit Drift Detection." *2015 international joint conference on neural networks (IJCNN)*. IEEE, 2015.
3. Cavalcante, Rodolfo C., et al. "Computational Intelligence and Financial Markets: A Survey and Future Directions." *Expert Systems with Applications* 55 (2016): 194-211.
4. Cavalcante, Rodolfo C., Leandro L. Minku, and Adriano LI Oliveira. "FEDD: Feature Extraction for Explicit Concept Drift Detection in time series." *Neural Networks (IJCNN), 2016 International Joint Conference on*. IEEE, 2016.
5. Ditzler, Gregory, et al. "Learning in nonstationary environments: A survey." *IEEE Computational Intelligence Magazine* 10.4 (2015): 12-25.



## Referências

1. Dongre, Priyanka B., and Latesh G. Malik. "A review on real time data stream classification and adapting to various concept drift scenarios." *Advance Computing Conference (IACC), 2014 IEEE International*. IEEE, 2014.
2. Gama, João, et al. "A survey on concept drift adaptation." *ACM Computing Surveys (CSUR)* 46.4 (2014): 44.
3. Krawczyk, Bartosz, et al. "Ensemble learning for data stream analysis: a survey." *Information Fusion* 37 (2017): 132-156.
4. Minku, Leandro L., and Xin Yao. "DDD: A new ensemble approach for dealing with concept drift." *IEEE transactions on knowledge and data engineering* 24.4 (2012): 619-633.
5. Zliobaite, Indre, et al. "Next challenges for adaptive learning systems." *ACM SIGKDD Explorations Newsletter* 14.1 (2012): 48-55.

# Previsão de Séries Temporais na Presença de Mudança de Conceito

Gustavo H. Ferreira de Miranda Oliveira  
gustavo.oliveira@penedo.ufal.br



Centro de Informática – UFPE  
27/10/2022